🔍 DÉTECTION DE FAKE NEWS POLITIQUES

Follow-Up — Projet Data Science & Business Intelligence

Master 2 Epitech — Avril 2026

GROUPE 2

Alexis FAYAN • Yassin CHAAIRATE • Jacqueline MARIANADIN

Ethan HARY • Aissatou-Blondin DIOP

01 PROBLÉMATIQUE & CONTEXTE

💡 **PROBLÉMATIQUE**

Peut-on détecter automatiquement les fake news politiques à partir du texte et des métadonnées du locuteur ?

📊 **DATASETS**

LIAR Dataset — 12 800 déclarations politiques US

Annotées par PolitiFact (fact-checkers pros)

6 niveaux de véracité → simplifié en fake / real

FakeNewsNet — ~1 000 articles (test généralisation)

🎯 **APPROCHE**

Classification binaire : fake vs real

TF-IDF + Word2Vec + métadonnées speaker

3 modèles classiques : LogReg, RF, XGBoost

1 modèle deep learning : BERT fine-tuné

Évaluation : accuracy, F1, SHAP, biais

02 MÉTHODOLOGIE

1

EDA

Exploration des données, stats, wordclouds

→

2

Prétraitement

Nettoyage texte, mapping binaire fake/real

→

3

Features

TF-IDF (10K), Word2Vec, métadonnées

→

4

Modèles

LogReg, RF, XGBoost + BERT

→

5

Évaluation

Cross-val 5-fold, GridSearch, confusion matrix

🔧 TECHNIQUES CLÉS

TF-IDF : transforme le texte en vecteur de fréquences (10 000 features, unigrams + bigrams)

Word2Vec : représentation dense du texte (300 dimensions) — comparé à TF-IDF

Cross-validation 5-fold : on divise le train en 5 parties pour valider la stabilité

SHAP values : on explique POURQUOI le modèle prédit fake ou real (interprétabilité)

BERT : modèle deep learning pré-entraîné, fine-tuné avec early stopping + warmup

03 RÉSULTATS

	Accuracy	F1 macro	
Logistic Regression	~64%	~64%	Baseline solide, interprétable
Random Forest	~62%	~61%	Bon en ensembles, léger underfitting
XGBoost	~73%	~72%	🏆 MEILLEUR — exploite les métadonnées
BERT	~64%	~61%	Text-only, pas de métadonnées

💡 Insight clé : les métadonnées (credit history) apportent +10 pts d'accuracy. Le texte seul ne suffit pas.

04 GÉNÉRALISATION & BIAIS

🌍 OUT-OF-DOMAIN (GÉNÉRALISATION)

Test sur FakeNewsNet PolitiFact (~1000 articles)

Dataset JAMAIS vu pendant l'entraînement

⚠️ Performance en baisse sur données externes

→ Les patterns LIAR ne se transfèrent pas bien

→ Vocabulaire et style différents entre datasets

C'est le "domain shift" : le modèle a appris des patterns spécifiques à LIAR, pas universels

⚖️ BIAIS & FAIRNESS

Analyse par affiliation politique du speaker

🔴 Problèmes identifiés :

→ Performances VARIENT selon le parti politique

→ Surreprésentation de certains speakers

→ Le credit history encode l'historique du speaker

✅ Solutions proposées :

→ Audit régulier par sous-groupe

→ Humain dans la boucle (pas d'automatisation totale)

→ Transparence des critères de classification

05 CONCLUSION & PROCHAINES ÉTAPES

Q1

Le modèle peut-il favoriser certains groupes ?

OUI — performances varient par parti.
Il faut un humain dans la boucle.

Q2

Les erreurs ont-elles des conséquences graves ?

OUI — faux positifs = censure,
faux négatifs = désinformation.

Q3

Peut-on détecter les fake news uniquement avec le texte ?

PARTIELLEMENT — le texte aide mais
les métadonnées sont cruciales (+10 pts).

🚀 PROCHAINES ÉTAPES POUR LA SOUTENANCE (17 avril)

- Ré-entraîner BERT avec les améliorations (early stopping, warmup, weight decay) et comparer
- Approfondir l'analyse SHAP et l'explicabilité des prédictions
- Préparer les réponses aux questions du jury sur les limites et les biais
- Finaliser les visualisations et la présentation orale